MLDR

Paquete R para exploración multietiqueta

David Charte Francisco Charte

11 nov 2015 – TAMIDA (Retos) – CAEPIA '15

Soft Computing and Intelligent Information Systems – Universidad de Granada

CLASIFICACIÓN DE DATOS

Aplicaciones:

- Detección de spam
- Diagnóstico de enfermedades
- Detección de fraude
- Predicción de riesgos
- ...

CLASIFICACIÓN TRADICIONAL

Clasificación binaria

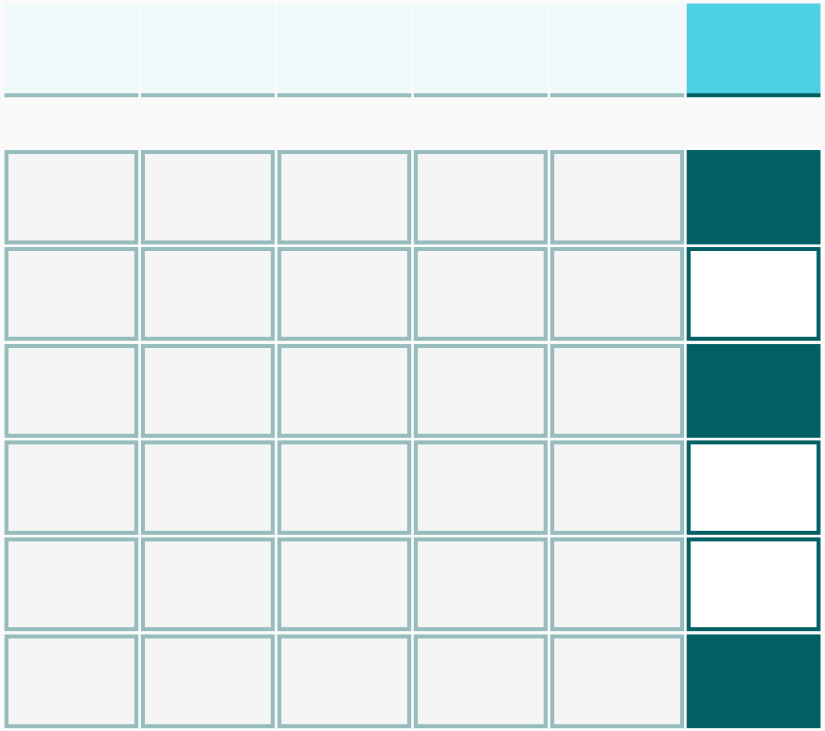

CLASIFICACIÓN TRADICIONAL

Clasificación binaria

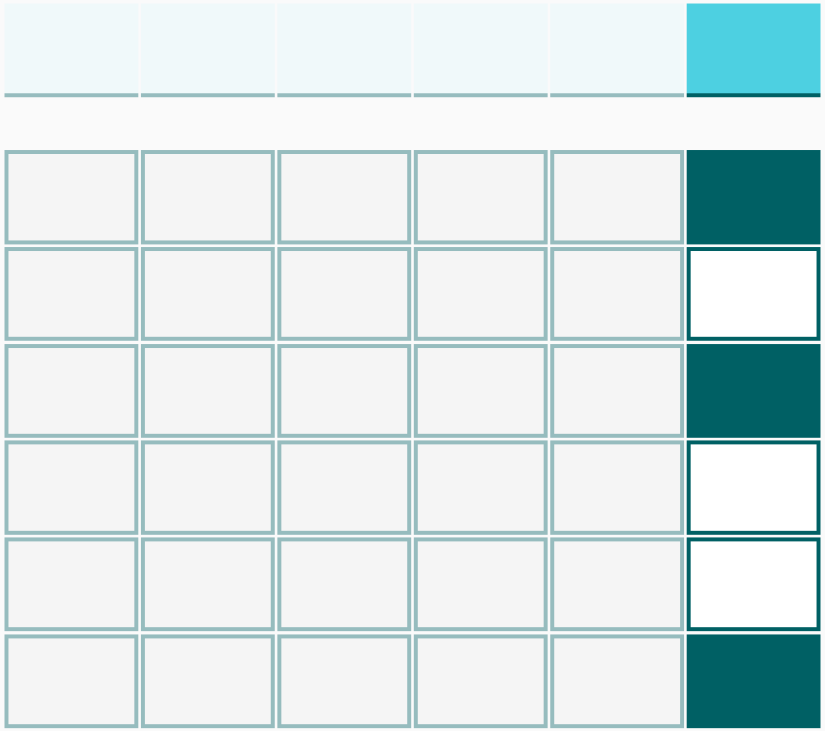

Clasificación multiclase

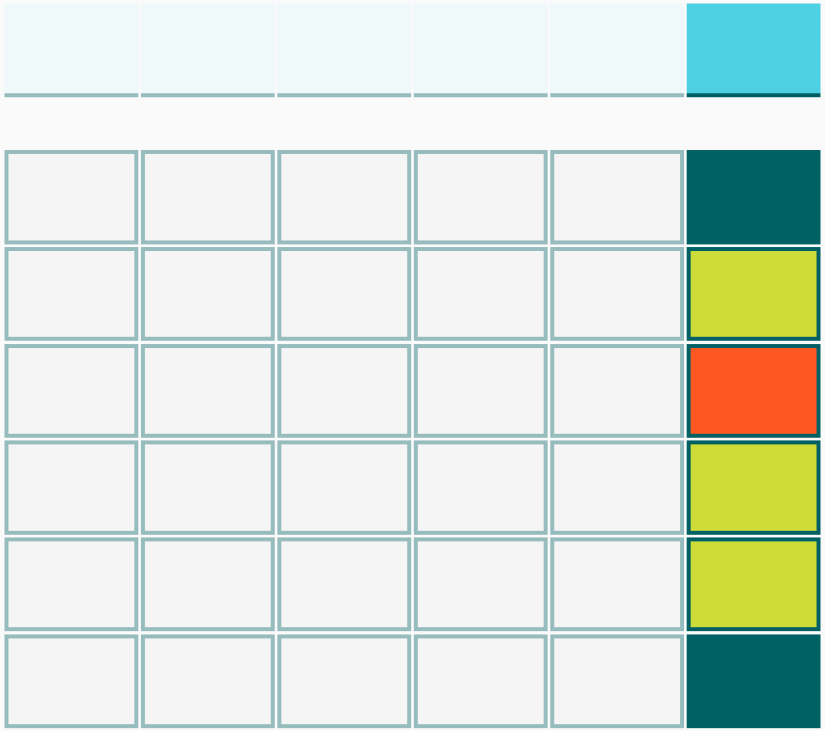

INFORMACIÓN NO BINARIA/MULTICLASE

- Escenas/elementos en fotografías
- Publicaciones de texto
- Contenido multimedia
- ...

Categorías no excluyentes $\Rightarrow$ Etiquetas

CLASIFICACIÓN MULTIETIQUETA

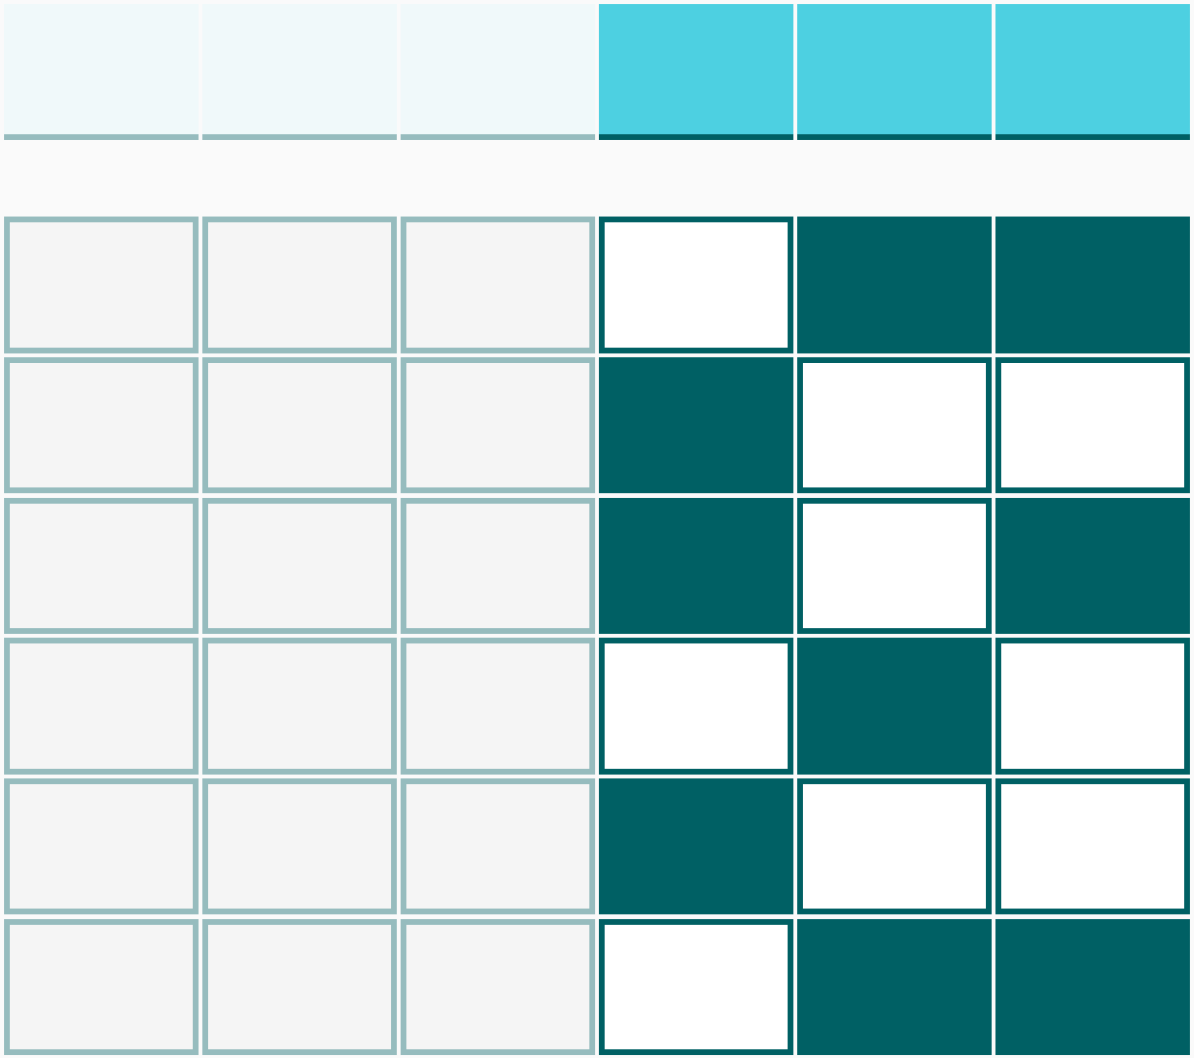

CLASIFICACIÓN MULTIETIQUETA

- Instancia: $(X, Y) \in X^1 \times X^2 \times \cdots \times X^f \times \mathcal{P}(L)$
- Para cada instancia hay $2^{|L|}$ posibles predicciones
- ¿Dependencia entre etiquetas?

CLASIFICACIÓN MULTIETIQUETA

- Instancia: $(X, Y) \in X^1 \times X^2 \times \cdots \times X^f \times \mathcal{P}(L)$
- Para cada instancia hay $2^{|L|}$ posibles predicciones
- ¿Dependencia entre etiquetas?

- Adaptación de algoritmos
- Transformación de datos
  - Binary Relevance: 1 problema multietiqueta $\sim |L|$ problemas binarios
  - Label Powerset: 1 problema multietiqueta $\sim$ 1 problema multiclase con $2^{|L|}$ clases

CLASIFICACIÓN MULTIETIQUETA

- Instancia: $(X, Y) \in X^1 \times X^2 \times \cdots \times X^f \times \mathcal{P}(L)$
- Para cada instancia hay $2^{|L|}$ posibles predicciones
- ¿Dependencia entre etiquetas?

- Adaptación de algoritmos
- Transformación de datos
  - Binary Relevance: 1 problema multietiqueta $\sim |L|$ problemas binarios
  - Label Powerset: 1 problema multietiqueta $\sim$ 1 problema multiclase con $2^{|L|}$ clases

- Nuevas métricas para obtener más información acerca de los datos

ÍNDICE

MOTIVACIÓN

- Necesidad de una herramienta accesible para exploración de datos multietiqueta
- Potencial de R para manejo de datos: estructuras de datos, instrucciones vectorizadas...
- Paquetes de gráficos disponibles para R
- Facilidad de interacción desde la consola interactiva de R

INSTALACIÓN Y CARGA

Disponible en CRAN

```
install.packages("mldr")
library(mldr)
```

INSTALACIÓN Y CARGA

Disponible en CRAN

```
install.packages("mldr")
library(mldr)

mldrGUI()
```

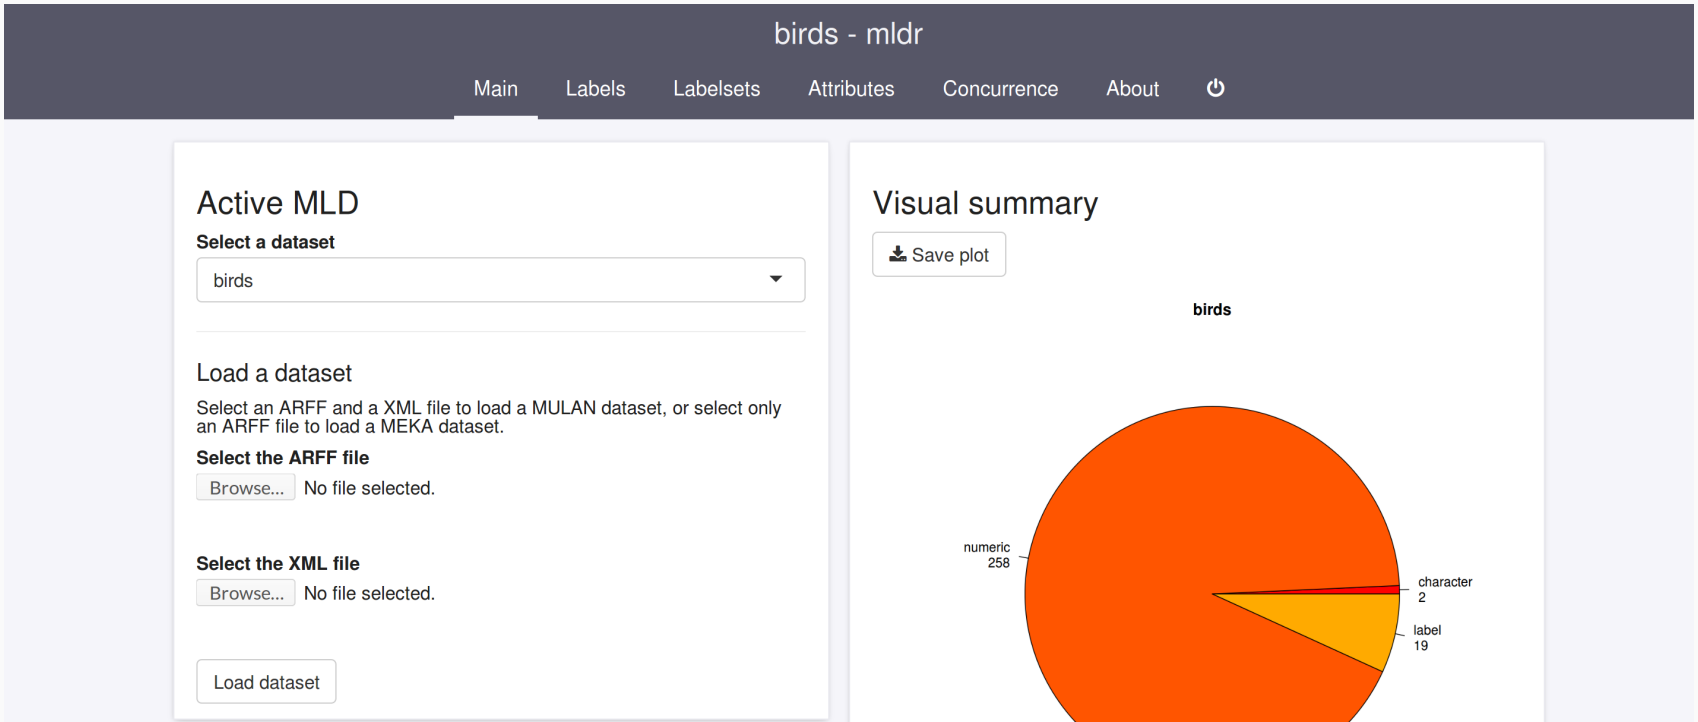

ESTRUCTURA DE UN OBJETO MLDR

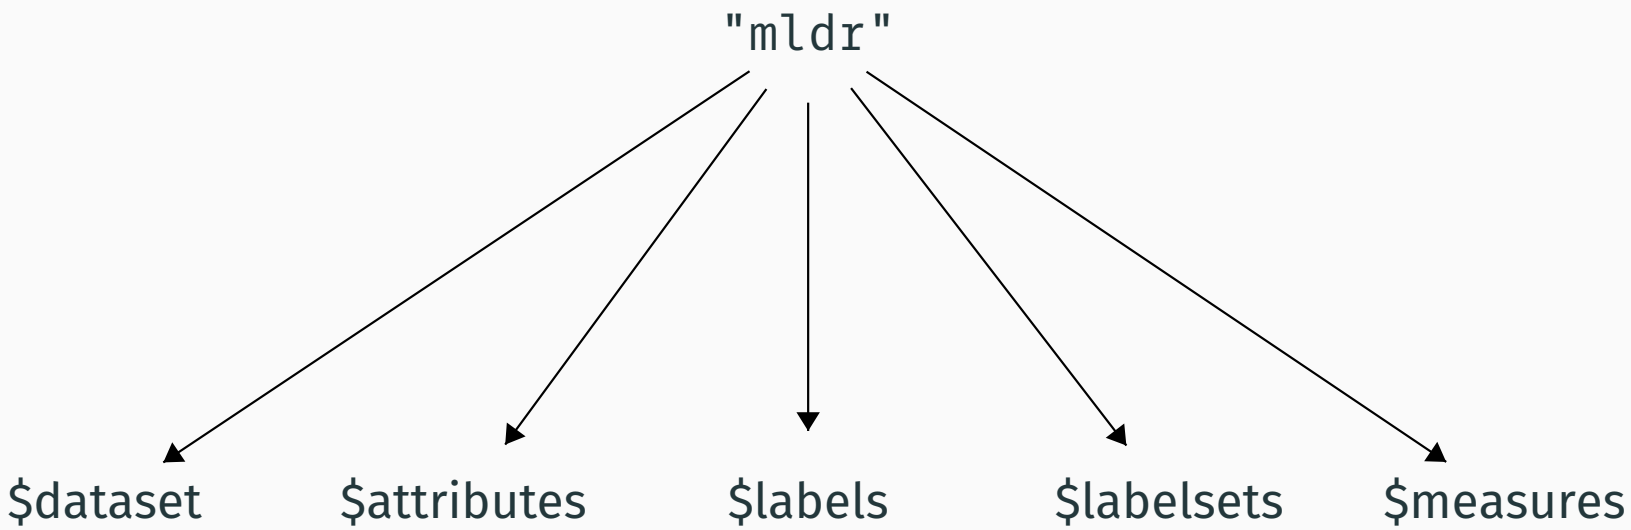

LECTURA Y CREACIÓN DE DATASETS

- Datasets en formato ARFF de Mulan y MEKA:

```
emotions <- mldr("emotions")
enron <- mldr("ENRON-F", use_xml = FALSE)
```

LECTURA Y CREACIÓN DE DATASETS

- Datasets en formato ARFF de Mulan y MEKA:

```
emotions <- mldr("emotions")
enron <- mldr("ENRON-F", use_xml = FALSE)
```

- Datasets de ejemplo: *emotions*, *birds*, *genbase*

LECTURA Y CREACIÓN DE DATASETS

- Datasets en formato ARFF de Mulan y MEKA:

```
emotions <- mldr("emotions")
enron <- mldr("ENRON-F", use_xml = FALSE)
```

- Datasets de ejemplo: *emotions*, *birds*, *genbase*

- Creación de nuevos datasets desde `data.frames`:

```
ej <- data.frame(matrix(rnorm(1000), ncol = 10))
ej$label1 <- c(sample(c(0,1), 100, replace = TRUE))
ej$label2 <- c(sample(c(0,1), 100, replace = TRUE))
mld <- mldr_from_dataframe(ej, labelIndices = c(11, 12))
write_arff(mld, "ejemplo_mld", write.xml = TRUE)
```

LECTURA Y CREACIÓN DE DATASETS

- Datasets en formato ARFF de Mulan y MEKA:

```
emotions <- mldr("emotions")
enron <- mldr("ENRON-F", use_xml = FALSE)
```

- Datasets de ejemplo: *emotions*, *birds*, *genbase*

- Creación de nuevos datasets desde `data.frames`:

```
ej <- data.frame(matrix(rnorm(1000), ncol = 10))
ej$label1 <- c(sample(c(0,1), 100, replace = TRUE))
ej$label2 <- c(sample(c(0,1), 100, replace = TRUE))
mld <- mldr_from_dataframe(ej, labelIndices = c(11, 12))
write_arff(mld, "ejemplo_mld", write.xml = TRUE)
```

- Filtrado de datasets

OBTENCIÓN DE MEDIDAS

```
summary(emotions)
```

```
num.attributes  num.instances  num.labels  num.labelsets
            78            593           6             27
num.single.labelsets  max.frequency  cardinality    density
                   4             81     1.868465  0.3114109
  meanIR     scumble
1.478068  0.01095238
```

OBTENCIÓN DE MEDIDAS

```
summary(emotions)
```

```
num.attributes  num.instances  num.labels  num.labelsets
            78            593           6             27
num.single.labelsets  max.frequency  cardinality    density
                   4             81     1.868465  0.3114109
  meanIR     scumble
1.478068  0.01095238
```

```
emotions$labels
```

```
                index count      freq    IRLbl     SCUMBLE
amazed-suprised    73   173 0.2917369 1.526012 0.002159173
happy-pleased      74   166 0.2799325 1.590361 0.014332319
relaxing-calm      75   264 0.4451939 1.000000 0.023786461
quiet-still        76   148 0.2495784 1.783784 0.023131538
sad-lonely         77   168 0.2833052 1.571429 0.016133470
angry-aggresive    78   189 0.3187184 1.396825 0.001331189
```

OBTENCIÓN DE MEDIDAS

emotions - mldr

Main | Labels | Labelsets | Attributes | Concurrence | About

Show 25 entries Copy Print Save

Search:

Label	index	count	freq	IRLbl	SCUMBLE
amazed-suprised	73	173	0.2917369	1.526012	0.002159173
happy-pleased	74	166	0.2799325	1.590361	0.014332319
relaxing-calm	75	264	0.4451939	1.000000	0.023786461
quiet-still	76	148	0.2495784	1.783784	0.023131538
sad-lonely	77	168	0.2833052	1.571429	0.016133470
angry-aggresive	78	189	0.3187184	1.396825	0.001331189
Label	index	count	freq	IRLbl	SCUMBLE

Showing 1 to 6 of 6 entries

Previous 1 Next

Save plot

Choose range of labels to plot

1 2 3 4 5 6

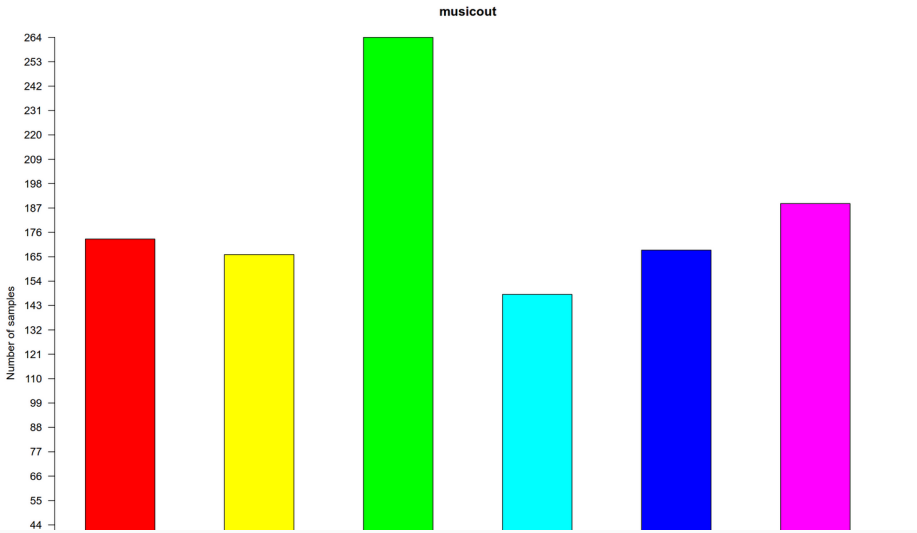

GENERACIÓN DE GRÁFICOS

```
plot(emotions, type = "LSB")
```

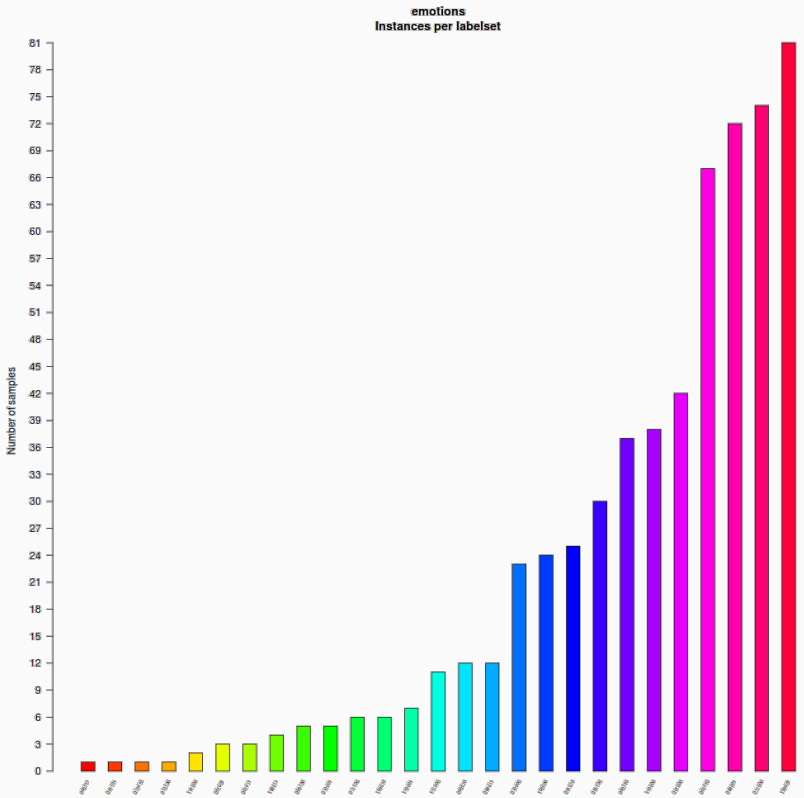


```
plot(emotions, type = "LC")
```

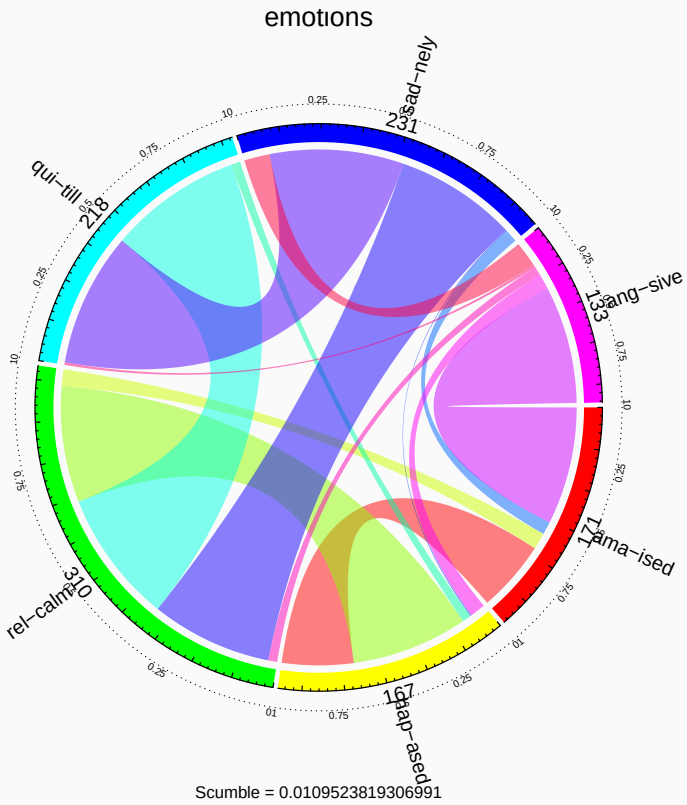

INFORME DE CONCURRENCIA

Búsqueda de etiquetas difíciles

emotions - mldr

Main Labels Labelsets Attributes Concurrence About

Concurrence analysis

The SCUMBLE level for each label is shown in the table at the left.

In the following table the minority labels most affected by SCUMBLE are shown.

For each one of them, the names of the majority labels with interactions are provided.

Description	Value
Dataset	emotions
Mean SCUMBLE	0.0109523819306991
SCUMBLE CV	1.2645601166572
Minority labels with high SCUMBLE	happy-pleased, quiet-still, sad-lonely
quiet-still	relaxing-calm, angry-aggresive
sad-lonely	relaxing-calm, angry-aggresive
happy-pleased	relaxing-calm, angry-aggresive

Save plot

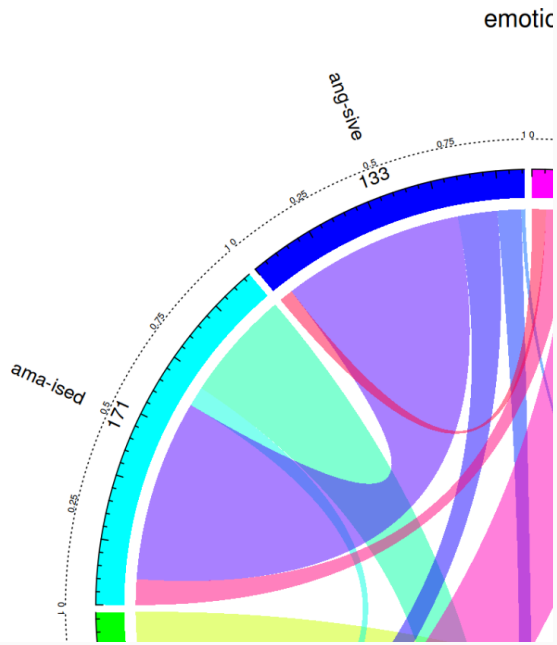

CLASIFICACIÓN CON MLDR

- Transformaciones Label Powerset y Binary Relevance
- 19 métricas de evaluación de resultados
- (*Pronto*) Interfaz común para implementación de clasificadores

```
mldr_evaluate(emotions, predictions)
```

```
List of 20
 $ Accuracy        : num 0.912
 $ AUC             : num 0.916
 $ AveragePrecision: num 0.669
 $ Coverage        : num 2.72
 $ FMeasure        : num 0.942
 $ HammingLoss     : num 0.0883
 $ MacroAUC        : num 0.919
 $ MacroFMeasure   : num 0.865
 $ MacroPrecision  : num 0.805
 $ MacroRecall     : num 0.936
 $ MicroAUC        : num 0.918
 $ MicroFMeasure   : num 0.868
 $ MicroPrecision  : num 0.811
 $ MicroRecall     : num 0.935
 $ OneError        : num 0.111
 $ Precision       : num 0.927
 $ RankingLoss     : num 0.508
 $ Recall          : num 0.927
 $ SubsetAccuracy  : num 0.831
 $ ROC             :List of 15
```

GRACIAS POR SU ATENCIÓN

MLDR

Paquete R para exploración multietiqueta

Repositorio CRAN: `http://cran.r-project.org/web/packages/mldr/`

Proyecto en GitHub: `https://github.com/fcharte/mldr`

Aplicación en ShinyApps: `https://fdavidcl.shinyapps.io/mldr`